PSet 3 · Experimentación y selección del modelo

Tierra · Rodríguez · Rodríguez · Cadena · Jarrín · ECU 911

EN EJECUCIÓN: resultados incompletos

Objetivo del PSet 1: anticipar alta demanda cantonal a t+3 y t+7 para revisión humana; reducir al menos 10% los días de alta demanda no anticipados frente a la regla estacional. Se conserva y=1 cuando el conteo objetivo supera estrictamente P90 del cantón y weekday.

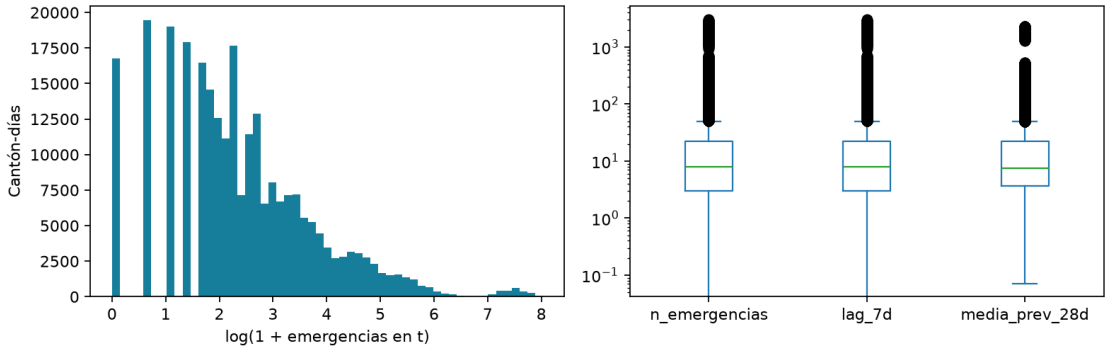
Fuente: ECU911Final.OBT.OBT_EMERGENCIAS_CANTON_DIA. Snapshot 2021-07-01 a 2026-09-30; 429,632 filas × 37 columnas, 224 unidades. La OBT actual amplía el histórico del PSet 2 hasta septiembre de 2026.

SHA256: 1191426ba6930eda1b9334728a41b545acd5a83425afb05e29f80c3ceea06e55

1. EDA

La EDA que guía decisiones usa train; el hold-out permanece reservado. Se revisaron esquema/nulos, descriptivos, prevalencia, IQR y |Z|>=3. Se usa Spearman por asimetría y asociaciones monótonas; no se eliminan picos automáticamente porque son el fenómeno objetivo.

Hallazgo y evidencia en train	Consecuencia experimental
Escalas cantonales y cola del volumen: asimetría=9.913; ceros=6.45%; IQR flags=32267	Usar Spearman y ratios de tendencia/cambio; no borrar picos reales como outliers.
Heterogeneidad cantonal: media cantonal P10=1.770, P90=68.391	Escalado dentro de fold, features relativas y evaluación por estrato de volumen.
Distribución real de alta demanda: prevalencia train t+3=8.21%, t+7=8.22%	Comparar AP (PR-AUC no interpolada); calibrar umbral en OOF, no en test.
Patrón semanal observado: medias por weekday: {0: 37.82, 1: 35.27, 2: 36.44, 3: 37.71, 4: 42.68, 5: 47.13, 6: 51.07}	Incluir sin/cos del día objetivo y media de cuatro ocurrencias; medir aporte con ablación.



Train: 260,288 filas. El año inicial de calibración tiene 81,760 filas y se reserva para P90. Esquema, descriptivos, nulos y outliers por columna se muestran completos en el notebook 01.

2. Features

Derivada / codificación	Justificación y disponibilidad
tendencia_7_28=(media7+1)/(media28+1)	Escalas cantonales muy distintas en EDA; cambio relativo de nivel. Ambas medias usan pasado anterior a t.
cambio_semanal=(n_t-lag7)/(lag7+1)	Contraste con la semana previa; n_t conocido al cierre t bajo feed diario.
estacional_relativa=(media4_weekday+1)/(media28+1)	EDA muestra patrón semanal. Para t+3 usa t-4,-11,-18,-25; t+7 usa t,t-7,-14,-21.
sin/cos del weekday y mes objetivo	Calendario conocido de antemano; representa ciclos sin saltos artificiales.
Cantón/provincia/región/weekday	One-hot ajustado al train de cada fold; categorías nuevas ignoradas.

Prueba de disponibilidad: las derivaciones no usan desplazamientos negativos ni obj_*. Se excluyen columnas fuera de la allowlist y la marca retrospectiva de anomalía. La disponibilidad diaria es un supuesto de evaluación retrospectiva: el portal público publica por mes.

Horizonte	AP sin ratios	AP con ratios	Delta / > SD
t+3	0.179	0.181	0.001 / False
t+7	0.180	0.182	0.001 / False

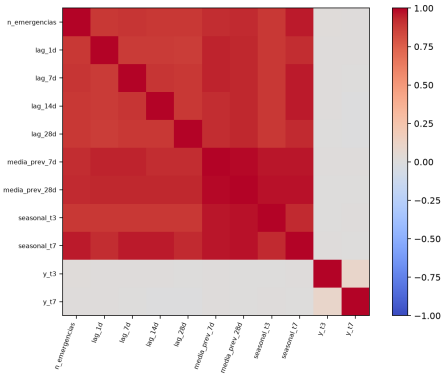
Ablación con logística, mismos folds: retirar conjuntamente los tres ratios. Una mejora menor a la variación entre pliegues no demuestra aporte; no se oculta un resultado negativo.

3. Preparación y validación

Calibración P90: primer año, hasta 2022-06-30; es parte del bloque de entrenamiento, separado del ajuste de clasificadores. P90 se congela antes de los folds para mantener la misma etiqueta. Hold-out: 20% final de fechas, desde 2025-09-12; se retiran siete días previos al corte y los objetivos finales no observados.

Tres folds expansivos con TimeSeriesSplit sobre fechas únicas y gap de siete días. Todos los cantones del día permanecen juntos; max(fecha_train)+7 < min(fecha_validación). Mediana, StandardScaler y one-hot se ajustan exclusivamente con train en Pipeline/ColumnTransformer de src/pipeline.py.

Métrica técnica común: Average Precision (AP, PR-AUC no interpolada). Métrica de negocio: (FN_estacional - FN_modelo)/FN_estacional; indefinida si FN_estacional=0. El umbral se fija en OOF minimizando 5FN+1FP con precision>=0.30; son supuestos relativos de sensibilidad, no dólares ni costos validados con ECU 911.



4. Diseño experimental

Primero se entrenaron ambas bases para ambos horizontes: Dummy de clase más frecuente y regla del PSet 1 (promedio de cuatro weekdays previos > P90). Su score media/P90 sirve para ordenar, no es probabilidad calibrada. Cinco familias con defaults salvo semilla: logística, random forest, hist gradient boosting, MLP y GaussianNB. Igual preparación, fechas y AP.

Fase	Mínimo implementado, ambos horizontes	Corridas exportadas
Baselines	4	4
Candidatos	10	10
Tuning	180 hijas + 6 padres	10 + 6
Final	4	0
Ablación / LLM	2 / 2	2 / 2

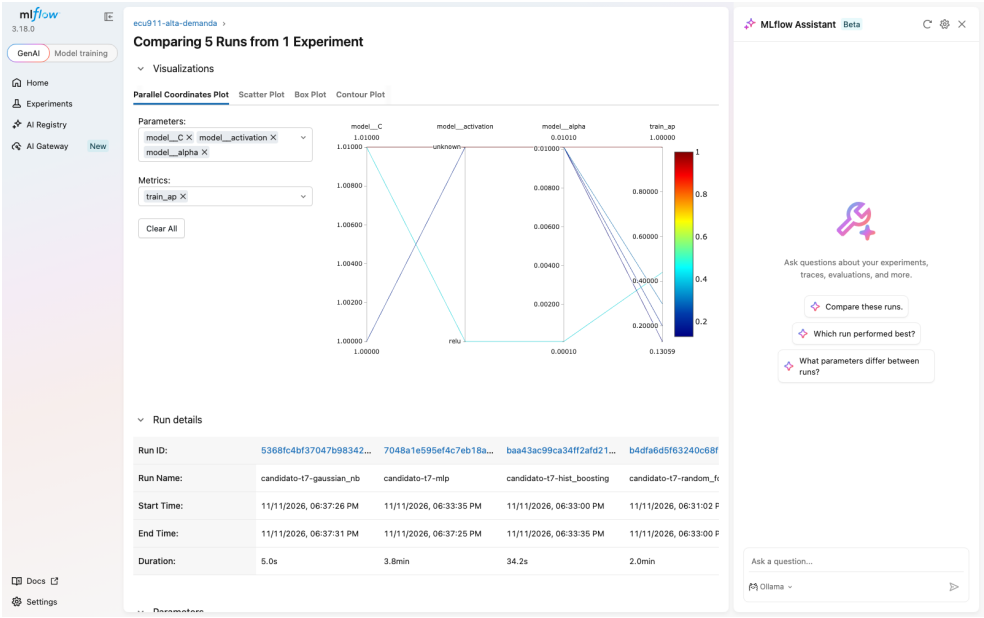
MLflow en Docker: backend SQLite y artifact store en volúmenes persistentes, servidos por proxy. Cada configuración guarda hiperparámetros/semilla, tabla/corte/hash, train AP, CV media y SD, tiempos, folds, advertencias, fase/familia y commit/hash de código. Se registra el pipeline completo con firma y ejemplo. Tuning usa corridas hijas; docs/corridas.csv se exporta con mlflow.search_runs.

Prueba zero-shot Qwen 2.5 1.5B local	AP	Precision / recall
t+3: n=100; run 5d3d84fc7ae94ebab12045afe88c2581	0.090	0.000 / 0.000
t+7: n=100; run 9f84f8715649450bb07c8f3207431dc6	0.136	0.000 / 0.000

Ollama sin API key: JSON con probability, temperatura 0, prompt y respuestas guardados. Muestra aleatoria del último fold, sin etiquetas en el prompt y sin test. Se comparó contra OOF de las mismas filas. Umbral exploratorio .70 del memo; la muestra no participa en el ranking de CV completa ni prueba calibración.

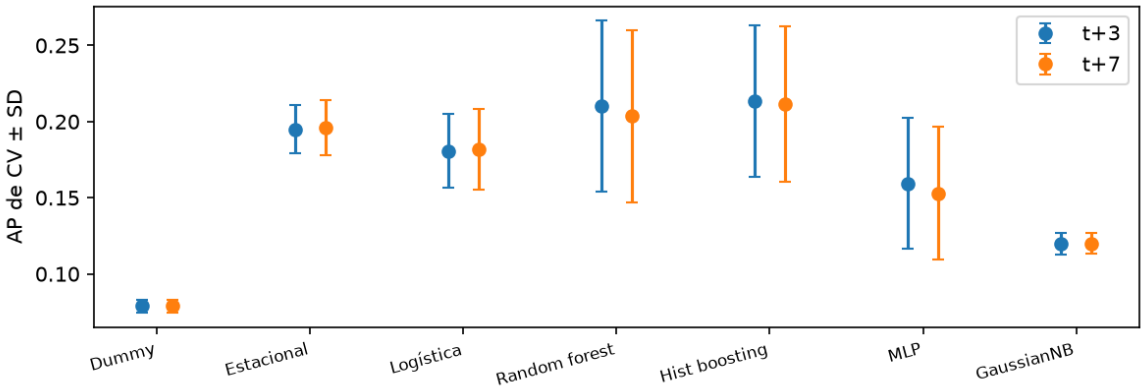
AP en las MISMAS 100 filas de validación	t+3	t+7
Dummy	0.090	0.090
Estacional	0.235	0.135
Logística	0.302	0.254
Random forest	0.320	0.231
Hist boosting	0.332	0.302
MLP	0.245	0.328
GaussianNB	0.165	0.141
Qwen 2.5 1.5B	0.090	0.136

En esta prueba, Qwen coincide con la AP del Dummy y no emite alertas al umbral .70. No se demuestra beneficio predictivo; se conserva el resultado negativo.



5. Resultados

h / modelo	Train AP	CV AP ± SD	Brecha	LR	Ajuste s
3 / Dummy	0.082	0.079 ± 0.004	0.003	NA	1.8
3 / Estacional	0.178	0.195 ± 0.016	-0.017	NA	0.0
7 / Dummy	0.082	0.079 ± 0.004	0.003	NA	1.7
7 / Estacional	0.179	0.196 ± 0.018	-0.016	NA	0.0
3 / Logística	0.200	0.181 ± 0.024	0.019	NA	6.0
3 / Random forest	1.000	0.210 ± 0.056	0.790	NA	88.6
3 / Hist boosting	0.301	0.213 ± 0.050	0.088	0.1	28.8
3 / MLP	0.453	0.160 ± 0.043	0.294	0.001	230.3
3 / GaussianNB	0.131	0.120 ± 0.007	0.011	NA	3.3
7 / Logística	0.200	0.182 ± 0.027	0.019	NA	6.2
7 / Random forest	1.000	0.203 ± 0.056	0.797	NA	96.8
7 / Hist boosting	0.299	0.212 ± 0.051	0.087	0.1	27.1
7 / MLP	0.440	0.153 ± 0.044	0.287	0.001	227.9
7 / GaussianNB	0.131	0.120 ± 0.007	0.011	NA	2.7



No superan ambas bases por AP de CV: t+3 Logística, t+3 MLP, t+3 GaussianNB, t+7 Logística, t+7 MLP, t+7 GaussianNB.

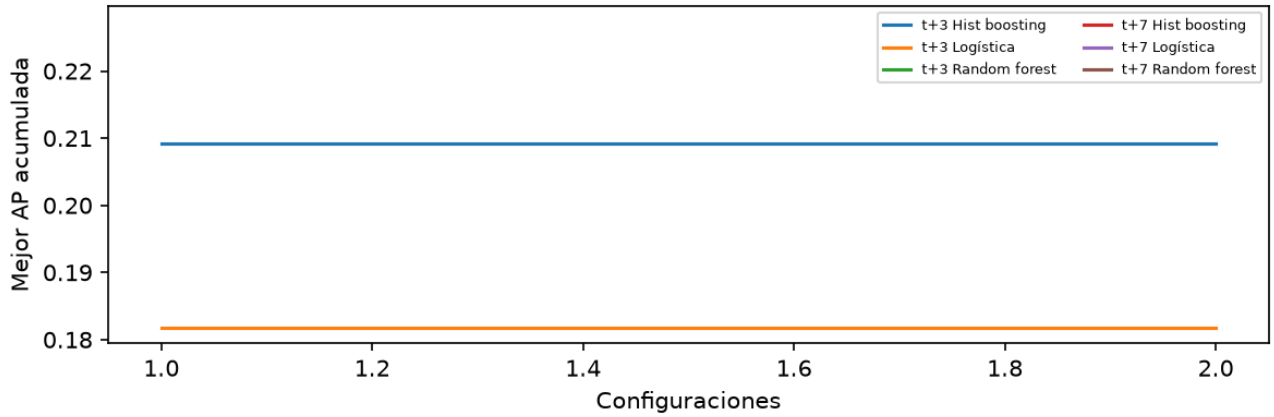
Mayor brecha observada: t+7 Random forest, train 1.000 frente a CV 0.203 (brecha 0.797), compatible con sobreajuste. La validación temporal y la dispersión entre folds determinan selección, no el ajuste aparente de train.

Ajuste s suma entrenamiento en folds y refit final; se registra también tiempo transcurrido con scoring. LR=NA si no aplica. Advertencias de convergencia se conservan en los artefactos; un default que no converge sigue siendo evidencia del experimento por defecto.

6. Tuning

Se seleccionan los tres mejores defaults de cada horizonte por AP media de CV. Búsqueda aleatoria reproducible (ParameterSampler, semilla 42), 30 configuraciones por familia y los mismos folds. Permite explorar órdenes de magnitud con presupuesto fijo y registrar cada configuración como nested run con su modelo completo.

LR y regularización usan escala logarítmica; complejidad y número de iteraciones tienen rangos acotados para controlar costo. Si delta AP no supera la mayor SD de default y ajustado, no se presenta como mejora demostrada y se conserva default para la selección.



Tuning aún no completado; no se declaran mejoras sin medir.

Se compara ganador y segundo de familias distintas. Diferencia mayor a la SD es una regla descriptiva, no prueba formal de significancia. El uso de los mismos folds para tuning y selección puede ser optimista; test permanece independiente.

7. Decisión

Selección y evaluación final aún pendientes.

8. Limitaciones

La fuente pública mensual no satisface la disponibilidad diaria asumida; esta es evaluación retrospectiva condicionada a datos oportunos. Enero 2024 se conserva con anomalía sin causa confirmada; no se usa su marca como predictor. P90 congelado puede perder vigencia y la prevalencia cambia. Geografía del PSet 2 contiene correcciones retrospectivas. Sin población INEC, capacidad operativa ni ID de incidente no se concluye saturación, exactitud factual o reducción de tiempos de respuesta. Costos y precisión mínima son supuestos; requieren validación institucional. Tuning/selección comparten folds; Qwen se evalúa en una muestra pequeña y temperatura cero no garantiza estabilidad entre versiones.

Fuentes: CD_PSet_3.pdf; memo PSet 1; github.com/junilai/Pset_2 (cc4df2dc56d9f17691956ba9c325245726eeba9b); documentación oficial de sklearn y MLflow.