PSet 3 · Experimentación ECU 911

BORRADOR: EJECUCIÓN CON SNOWFLAKE PENDIENTE

Jarod Tierra · Felipe Rodríguez · Santiago Rodríguez · Juan Diego Cadena · Miguel Jarrín

Predecir demanda alta por cantón a t+3 y t+7. Se conserva y=1 cuando el conteo futuro supera estrictamente el P90 del cantón y weekday objetivo. La salida apoya la revisión humana de turnos; no asigna recursos. La meta del PSet 1 es reducir 10% los falsos negativos frente a la regla estacional, al menos a t+3.

Fuente: ECU911.OBT.OBT_EMERGENCIAS_CANTON_DIA. El repositorio del PSet 2, commit cc4df2dc56d9f17691956ba9c325245726eeba9b, documenta 422.912 filas, 224 unidades, 37 columnas y cobertura 2021-07 a 2026-08. Son antecedentes del PSet 2, no conteos revalidados en este experimento.

Estado: no existe snapshot autenticado en esta carpeta. La conexión local probada devolvió un error de autenticación. No se reportan métricas, hallazgos empíricos nuevos ni un ganador.

1. EDA

El notebook 01 inspecciona tipos, tamaño, nulos por columna, descriptivos, target, IQR y |Z|>=3. Se usa Spearman por tratarse de conteos asimétricos y relaciones potencialmente monótonas. Se conservan los picos: son la señal de negocio. La EDA que guía modelos usa solo el bloque de entrenamiento posterior al año inicial de calibración.

Verificación pendiente	Decisión prevista, sujeta a evidencia
Asimetría, ceros y escalas cantonales	Ratios de volumen; conservar outliers; evaluar por estrato.
Prevalencia real por horizonte	AP común a todos; umbral con precision mínima.
Patrón semanal y correlación con target	Calendario cíclico y media de cuatro weekdays.

Estas son hipótesis de diseño, no tres hallazgos ya observados. Los conteos y gráficos se insertan automáticamente al ejecutar la EDA real.

2. Features

src/pipeline.py contiene las transformaciones; los notebooks las importan. Las derivaciones son deterministas y las que usan historia se calculan con desplazamientos no negativos.

Feature	Disponibilidad / razón
tendencia_7_28 = (media7+1)/(media28+1)	Ambas medias excluyen t; representa cambio relativo de nivel.
cambio_semanal = (n_t - lag7)/(lag7+1)	Disponible al cierre t bajo fuente diaria oportuna; compara semanas.
estacional_relativa = (media4_weekday+1)/(media28+1)	t+3: t-4,-11,-18,-25; t+7: t,t-7,-14,-21.
sin/cos de weekday y mes objetivo	Calendario futuro conocido; geometría cíclica.
Cantón, provincia, región, weekday objetivo	One-hot dentro del fold; categorías desconocidas ignoradas.

La EDA registra el patrón semanal y la dispersión cantonal; la ablación de ratios con logística compara AP con/sin derivadas en idénticos pliegues. Si no supera la variación entre pliegues, no se afirma aporte demostrado. La relación con EDA queda pendiente hasta observar datos reales.

Disponibilidad real. El histórico público es mensual. Usar n_t y lags diarios simula una fuente disponible al cierre t. Las conclusiones son retrospectivas y condicionales a integrar un feed diario; no se demuestra disponibilidad operacional con el portal mensual. Se excluyen obj_*, nombre_feriado, indicadores retrospectivos como es_periodo_anomalo y columnas fuera de la allowlist.

3. Preparación y validación

Métrica técnica: AP (PR-AUC no interpolada). Métrica de negocio: reducción de falsos negativos frente al baseline estacional; meta del 10% del PSet 1. Ambas se conservan para los dos horizontes.

El primer año completo se reserva para estimar P90 por cantón/weekday; pertenece al bloque de entrenamiento y no se usa para entrenar clasificadores. Ese umbral se congela antes de todos los pliegues, evitando definir la etiqueta con futuro del fold. El 20% final de fechas es hold-out; se retiran siete días anteriores al corte. Train usa los días restantes posteriores al año inicial. Se excluyen objetivos t+7 no observados para comparar ambos horizontes en las mismas fechas.

CV: tres pliegues expansivos con TimeSeriesSplit sobre días únicos, gap=7 días, y todos los cantones de cada día en un mismo bloque. Se verifica max(fecha_train)+7 < min(fecha_validación). Aplicar el split directamente sobre filas cantón-día podría mezclar el mismo día entre particiones.

Mediana, one-hot y StandardScaler viven en Pipeline/ColumnTransformer y se ajustan solo en fit del fold. El modelo final se ajusta a todo train sin test. El split y hash quedan persistidos; un cambio exige un nuevo experimento, no volver a optimizar contra el hold-out.

4. Diseño experimental

Se entrenan primero DummyClassifier (clase más frecuente) y la regla del PSet 1: promedio de cuatro ocurrencias anteriores del weekday objetivo > P90. El score estacional ordena por media/P90 y no representa una probabilidad calibrada. Después se comparan cinco familias con defaults de sklearn y semilla fija: logística, random forest, hist gradient boosting, MLP y GaussianNB. La quinta familia probabilística evita añadir dependencias de modelos fundacionales.

Métrica común: Average Precision (AP), definida como PR-AUC no interpolada, adecuada al target desbalanceado. Se reportan AP de train, promedio ± desviación muestral de CV, brecha y segundos totales de CV más ajuste final. Una brecha positiva alta es evidencia compatible con sobreajuste; no se diagnostica solo por la AP de entrenamiento.

Fase	Por horizonte	Total t+3 / t+7
Baselines	2	4
Candidatos	5	10
Tuning	3 × 30	180 hijas + 6 padres
Final	2 finalistas	4
Ablación	1	2
LLM prompting	1, si hay endpoint	2 adicionales

Presupuesto implementado: 198 corridas evaluadas sin LLM (4+10+180+4), más dos ablaciones y seis padres de tuning. Los experimentos sintéticos no cuentan como evidencia del ECU 911.

Cada configuración registra semilla e hiperparámetros, tabla, corte y SHA256, métricas, folds, advertencias, fase, familia, commit/estado de Git y hash del código. Se almacena pipeline completo con firma y ejemplo de entrada. Los artefactos se sirven por MLflow; SQLite y archivos viven en dos volúmenes persistentes de Docker. docs/corridas.csv se exporta con mlflow.search_runs.

Evaluación LLM pendiente. Se configuró qwen2.5:1.5b mediante Ollama local, sin API key. src/datos.py (llm_trial) prepara zero-shot sobre una muestra del último fold, sin nombres geográficos ni fechas exactas. Falta la OBT real para medir su desempeño. Se compara contra candidatos en las mismas filas; esa muestra no sustituye CV completa ni participa en la selección final.

Captura de comparación MLflow pendiente: generar con -m src.datos captura después de las corridas reales.

5. Resultados

LR es la tasa de aprendizaje; NA significa que no corresponde al estimador. Los defaults se mantienen salvo semilla; las advertencias de convergencia quedan en MLflow.

Familia	Train / CV / brecha / LR / tiempo
Dummy	PENDIENTE DE SNOWFLAKE
Regla estacional	PENDIENTE DE SNOWFLAKE
Logística	PENDIENTE DE SNOWFLAKE
Random forest	PENDIENTE DE SNOWFLAKE
Hist boosting	PENDIENTE DE SNOWFLAKE
MLP	PENDIENTE DE SNOWFLAKE
GaussianNB	PENDIENTE DE SNOWFLAKE

No hay mediciones reales. La tabla se reemplaza al ejecutar las fases de entrenamiento. La ausencia de métricas impide concluir qué familia supera ambas líneas base o si hay sobreajuste.

Explicabilidad prevista: coeficientes estandarizados en logística; árboles/ensembles y MLP se inspeccionan con importancia por permutación en una muestra de train. Es descriptiva, no causal ni una medición independiente de generalización. El costo se compara por segundos de ajuste e inferencia en el mismo entorno; no se extrapola a costos monetarios ni latencias productivas.

6. Tuning

Los tres mejores defaults por AP media de CV se ajustan en cada horizonte. ParameterSampler usa búsqueda aleatoria reproducible con 30 configuraciones por familia y los mismos folds. Se prefiere a grilla porque cubre rangos continuos con presupuesto fijo; la evaluación explícita permite guardar cada configuración como nested run con su pipeline.

Familia	Espacio / justificación
Logística	C log-uniforme 1e-4..1e3; class_weight None/balanced; max_iter 500/1000.
Random forest	80..400 árboles; profundidad None/6/12/20; hojas 1..30; max_features sqrt/.3/.7; ponderación.
Hist boosting	LR log .01.. .3; iteraciones 80..300; hojas 7..63; L2 log 1e-4..10; min hoja 10..60.
MLP	(32),(64),(100),(64,32); alpha log 1e-6.. .1; LR log 1e-4..1e-2; 200/400 iter.; early stopping sí/no.
GaussianNB	var_smoothing log-uniforme 1e-12..1e-3: escala de regularización de varianzas.

Escalas logarítmicas exploran órdenes de magnitud de regularización/LR. Rangos enteros acotan complejidad y costo. Se registra el espacio realmente utilizado de los tres finalistas. Una mejora menor o igual a la mayor SD del default y del ajustado no se considera demostrada; en ese caso se conserva el default para la selección.

Tuning no ejecutado. No existen aún 180 corridas hijas, mejoras medidas ni gráficas de búsqueda. El código exige n_iter>=30 y guarda las configuraciones evaluadas individualmente.

Ganador y segundo pertenecen a familias distintas y se eligen antes de test. Se compara la diferencia de AP media con la mayor SD entre pliegues; esta regla descriptiva no es una prueba formal de significancia. Si la diferencia es pequeña, se declara incertidumbre. No se reajusta el ranking tras observar el hold-out.

7. Decisión

Reducción FN = (FN_estacional - FN_modelo)/FN_estacional; si el denominador es cero, se informa indefinida. Umbral inicial .70 del PSet 1 reemplazado por minimización OOF de 5FN+1FP, sujeto a precision>=0.30. Estos son costos relativos asumidos y precision mínima provisional, no costos validados con ECU 911. Si la restricción es inviable se declara. Umbral y finalistas se congelan antes de abrir test.

No hay ganador ni versiones registradas reales. Falta extraer la OBT, ejecutar experimentos y evaluar ambos finalistas una sola vez. No se afirma cumplir la meta del 10%.

Se usa un registro por horizonte: ecu911-alta-demanda-t3-modelo y ecu911-alta-demanda-t7-modelo; ambos con aliases champion y challenger. El notebook 05 carga por alias en kernel limpio y exige igualdad exacta de predicciones, AP local y AP registrada. Esta reproducción verifica el mismo resultado; no vuelve a seleccionar el modelo.

8. Limitaciones

(1) Latencia mensual: no hay prueba de inferencia operacional diaria. (2) Enero de 2024 se conserva como anomalía documentada; no se usa su marca retrospectiva como predictor. (3) P90 congelado limita adaptación a drift y puede alterar prevalencia futura. (4) Sin población INEC, personal disponible ni ID de incidente no se infiere saturación ni exactitud factual de los registros. (5) Geografía vigente del PSet 2 contiene reasignaciones retrospectivas. (6) Tuning y selección sobre los mismos folds tienen optimismo de selección; el hold-out final ofrece contraste independiente. (7) La métrica por estrato depende del volumen del año de calibración. (8) LLM en muestra limitada y costos asumidos exigen validación adicional.

Pendientes de entrega: credenciales Snowflake válidas, snapshot real, EDA empírica, 198 corridas evaluadas, prueba LLM, captura MLflow, registro, exportación de corridas y notebooks con resultados reales.

Fuentes: memo PSet 1 entregado por el equipo; instrucciones CD_PSet_3.pdf; https://github.com/junilai/Pset_2; documentación oficial de scikit-learn (TimeSeriesSplit, Average Precision) y MLflow (tracking server, sklearn log_model, Model Registry).